SBVCONC: Construção de Compiladores

Aula 06: Análise Sintática (Parsing)

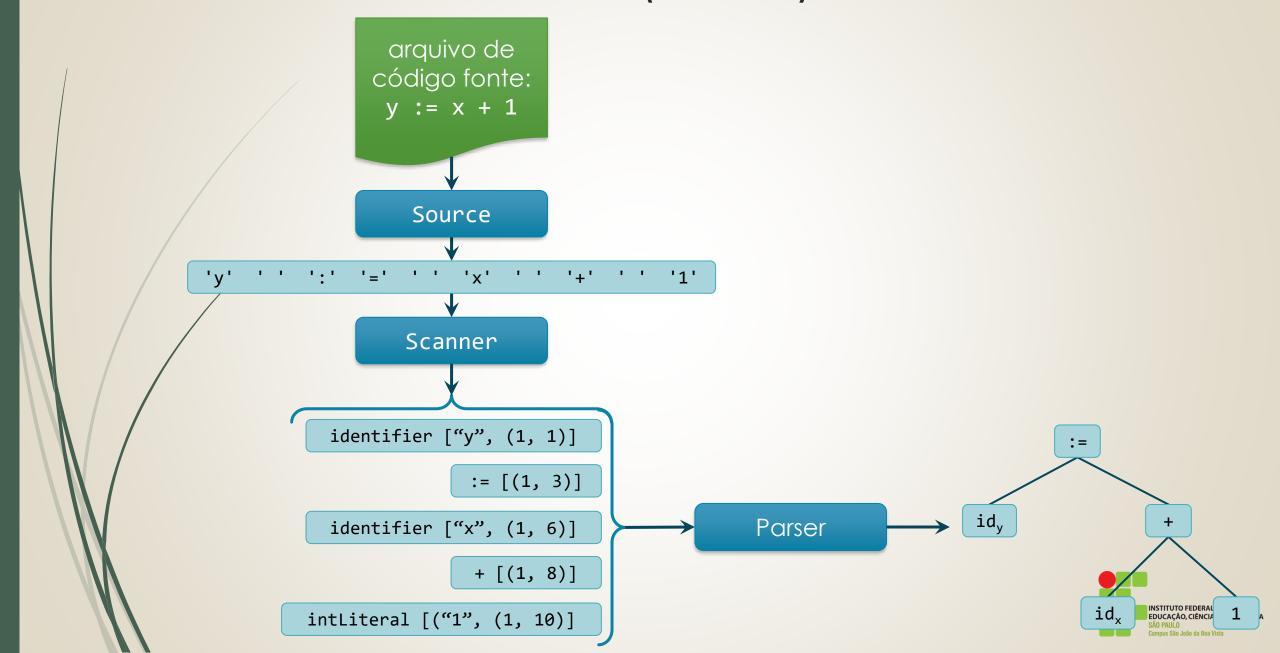


2/86 Analisador Sintático (Parser)

- Verifica se as regras gramaticais da linguagem são satisfeitas;
- A estrutura geral de um parser é baseada em gramáticas livres de contexto, representadas usando BNF/EBNF;
- Entrada: um fluxo de tokens do analisador léxico (scanner). Da perspectiva do parser, cada token é tratado como um símbolo terminal;
- Saída: uma representação intermediária do código fonte, por exemplo, árvores sintáticas abstratas.



Analisador Sintático (Parser)



4/86 Funções do Parser

- Reconhecimento da linguagem baseada na sintaxe, assim como definida na gramática livre de contexto;
- Tratamento/Recuperação de Erros;
- Geração de representação intermediária, no nosso caso, geração de árvores sintáticas abstratas;
- Nesta aula nosso foco será no reconhecimento da linguagem, nas próximas duas aulas lidaremos com o tratamento/recuperação de erros e a geração das árvores sintáticas abstratas.



5/86 Análise Descendente Recursiva

- Técnica de análise usada nessa disciplina: análise descendente recursiva com um único símbolo de lookahead. Vamos discutir rapidamente outras técnicas existentes no final dessa aula;
- Usa métodos recursivos para "descer" através da árvore de análise (análise top-down) enquanto o programa é analisado;
- O parser é construído sistematicamente a partir da gramática, aplicando uma série de refinamentos.



Transformações Iniciais da Gramática

- Iniciar com uma gramática não ambígua;
- Na gramática, separar as regras léxicas das regras estruturais:
 - O scanner tratará regras simples (operadores, identificadores etc);
 - Símbolos reconhecidos pelo scanner tornam-se símbolos terminais na gramática do parser;
- Eliminar recursões à esquerda;
- Realizar a fatoração à esquerda das regras sempre que possível;
- Algumas restrições gramaticais serão discutidas à seguir.



Análise Descendente Recursiva Refinamento 1

Para cada regra da gramática:

```
definimos um método do parser com o nome:
  parseN()
```

Exemplo, para a regra:

```
assignmentStmt = variable ":=" expression ";" .
definimos um método do parser com o nome:
  parseAssignmentStmt()
```

 As transformações na gramática podem ser usadas para simplificar a gramática antes de aplicar esse refinamento, por exemplo, a substituição de não-terminais.

8/86 Os Métodos da Análise Descendente Recursiva

- Os métodos na forma parseN() do parser funcionam da seguinte forma:
 - O método getSymbol() do scanner provê um símbolo de lookahead para os métodos de análise;
 - No início (entrada) da execução do método parseN(), o símbolo retornado pelo scanner deve ser um símbolo que está no início do lado direito da regra $N = \dots$
 - No fim (saída) da execução do método parseN(), o símbolo retornado pelo scanner deve ser o primeiro símbolo que segue uma frase sintática que corresponde à N
 - Se as regras de produção possuem referências recursivas, os métodos de análise também terão chamadas recursivas.



Analisando o Lado Direito da uma Regra

- Agora, nos atentaremos ao refinamento do método parseN() associado à regra de produção "N =" examinando a forma da expressão gramatical que está do lado direito da regra;
- Como exemplo, para a regra:

```
assignmentStmt = variable ":=" expression ";" .
definimos um método de análise com o nome de:
```

```
parseAssignmentStmt()
```

Focaremos na implementação sistemática desse método examinando, para isso, o lado direito da regra.



10/86 Análise Descendente Recursiva Refinamento 2

- Uma sequência de fatores sintáticos $F_1F_2F_3$... é reconhecida ao se analisar cada um dos fatores, um de cada vez e em ordem;
- \blacksquare Em outras palavras, o algoritmo para analisar $F_1F_2F_3$... \acute{e} , simplesmente:
 - O algoritmo usado para analisar F_1 , seguido de
 - \blacksquare O algoritmo usado para analisar F_2 , seguido de
 - \blacksquare O algoritmo usado para analisar F_3 , seguido de



11/86 Análise Descendente Recursiva Refinamento 2 (exemplo)

O algoritmo usado para analisar:

```
variable ":=" expression ";"
é simplesmente:
```

- O algoritmo usado para analisar variable, seguido de
- O algoritmo usado para analisar ":=", seguido de
- O algoritmo usado para analisar expression, seguido de
- O algoritmo usado para analisar ";"



12/86 Análise Descendente Recursiva Refinamento 3

Um único símbolo terminal t do lado direito de uma regra é reconhecido ao se invocar o método auxiliar de análise match(t), definido como:

```
private void match( Symbol expectedSymbol )
            throws IOException, ParserException {
    if ( scanner.getSymbol() == expectedSymbol )
        scanner.advance();
    else
        ... // throw ParserException
```

Exemplo: O algoritmo para reconhecer o operador de atribuição ":=" é simplesmente a invocação do método:

```
match( Symbol.assign );
```



13/86 Análise Descendente Recursiva Refinamento 4

- Um símbolo não-terminal N do lado direito de uma regra é reconhecido ao se invocar o método correspondente à regra N, ou seja, o algoritmo que reconhece o não-terminal N é simplesmente a invocação do método parseN();
- **Exemplo:** O algoritmo para reconhecer o símbolo não-terminal expression do lado direito de uma regra é simplesmente a invocação do método parse Expression().



14/86 Aplicação dos Refinamentos para a Análise Descendente Recursiva

Considere a regra da instrução de atribuição: assignmentStmt = variable ":=" expression ";" .

O método de análise completo que reconhece a instrução de atribuição é o seguinte:

```
public void parseAssignmentStmt() {
    parseVariable();
    match( Symbol.assign );
    parseExpression();
    match( Symbol.semicolon );
```



15/86 Conjuntos First e Follow

- A construção de um parser preditivo é auxiliada por duas funções associadas a uma gramática G;
- As funções *First* e *Follow* nos permitem preencher as entradas de uma tabela de análise preditiva para G, sempre que possível;
- Os conjuntos de tokens gerados pela função Follow também podem ser usados como tokens de sincronização durante a recuperação de erros.



16/86 Conjuntos First (Primeiros)

- O conjunto de todos os símbolos terminais que podem aparecer no início de uma expressão sintática α é denotado por $First(\alpha)$;
- \blacksquare A expressão sintática α é uma cadeia de símbolos gramaticais (terminais e não-terminais);
- Os conjuntos First provêm informações importantes que podem ser usadas para guiar as decisões durante o desenvolvimento do parser (tanto descendente quanto ascendente).



17/86 Regras para Computar os Conjuntos First

Se t é um símbolo terminal, então:

$$First(t) = \{t\}$$

- Se $E \to \varepsilon$ é uma produção, então adicione ε ao First(E):
- Se todas as strings derivadas de E não são vazias, então: $First(EF) = First\{E\}$
- Se algumas strings derivadas de E podem ser vazias, então: $First(EF) = First\{E\} \cup First\{F\}$
- ightharpoonup First(E|F) = First(E} U First(F)



18/86 Casos Especiais para a Computação dos Conjuntos First

- As regras abaixo podem ser derivadas como casos especiais das regras anteriores:
 - ightharpoonup First((E) *) = First(E)
 - ightharpoonup First((E)+) = First(E)
 - First((E)?) = First(E)
 - ightharpoonup First((E) * F) = First(E) U First(F)
 - ightharpoonup First(E) + F = First(E) se todas as strings derivadas de E não são vazias
 - ightharpoonup First(E) + F = First(E) + Fvazias
 - ightharpoonup First(E)? F) = First(E) U First(F)



19/86 Estratégia para Computar os Conjuntos First

 Usar uma abordagem de baixo para cima, ou seja, iniciar com regras mais simples e trabalhar em direção às regras mais complicadas (compostas).



Material Prof. Daniel Lucrédio (UFSCar)

Gramática

 $D \to \varepsilon$

$$S \to A B$$

$$A \to a A \mid a \mid d$$

$$B \to b B \mid c \mid A \mid Cd$$

$$C \to x \mid y \mid \varepsilon$$

$$First(abcd) = \{a\}$$

$$First(ABC) = \{a,d\}$$

$$First(AxCd) = \{a,d\}$$

$$First(BzSB) = \{b,c,a,d,x,y\}$$

$$First(CzSB) = \{x,y,z\}$$

$$First(SABC) = \{a,d\}$$

$$First(DAB) = \{a,d\}$$

$$First(DCe) = \{x,y,e\}$$

$$First(DC) = \{x,y,e\}$$



Material Prof. Daniel Lucrédio (UFSCar)

Gramática

$$S \rightarrow A B$$

$$A \rightarrow a A \mid a \mid d$$

$$B \rightarrow b B \mid c \mid A \mid Cd$$

$$C \rightarrow x \mid y \mid \varepsilon$$

$$D \to \varepsilon$$

a é terminal

$$First(abcd) = \{a\}$$

$$First(ABC) = \{a, d\}$$

$$First(AxCd) = \{a, d\}$$

$$First(BzSB) = \{b, c, a, d, x, y\}$$

$$First(CzSB) = \{x, y, z\}$$

$$First(SABC) = \{a, d\}$$

$$First(C) = \{x, y, \varepsilon\}$$

$$First(DAB) = \{a, d\}$$

$$First(DCe) = \{x, y, e\}$$

$$First(DC) = \{x, y, \varepsilon\}$$



Material Prof. Daniel Lucrédio (UFSCar)

Gramática

$$S \rightarrow A B$$

$$A \rightarrow a A \mid a \mid d$$

$$B \rightarrow b B \mid c \mid A \mid Cd$$

$$C \rightarrow x \mid y \mid \varepsilon$$

$$D \to \varepsilon$$

A não tem arepsilon à direita

$$First(ABC) = \{a, d\}$$

$$First(AxCd) = \{a, d\}$$

$$First(BzSB) = \{b, c, a, d, x, y\}$$

$$First(CzSB) = \{x, y, z\}$$

$$First(SABC) = \{a, d\}$$

$$First(C) = \{x, y, \varepsilon\}$$

$$First(DAB) = \{a, d\}$$

$$First(DCe) = \{x, y, e\}$$

$$First(DC) = \{x, y, \varepsilon\}$$



Material Prof. Daniel Lucrédio (UFSCar)

Gramática

 $D \to \varepsilon$

$$S \rightarrow A B$$

$$A \rightarrow a A \mid a \mid d$$

$$B \rightarrow b B \mid c \mid A \mid Cd$$

$$C \rightarrow x \mid y \mid \varepsilon$$

First
$$(abcd) = \{a\}$$

First $A \text{ não tem } \varepsilon \text{ à direita}$

First $(AxCd) = \{a,d\}$

First $(BzSB) = \{b,c,a,d,x,y\}$

First $(CzSB) = \{x,y,z\}$

First $(SABC) = \{a,d\}$

First $(DAB) = \{a,d\}$

First $(DCe) = \{x,y,e\}$

Material Prof. Daniel Lucrédio (UFSCar)

Gramática

$$S \rightarrow A B$$

$$A \rightarrow a A \mid a \mid d$$

$$B \rightarrow b B \mid c \mid A \mid Cd$$

$$C \rightarrow x \mid y \mid \varepsilon$$

$$D \rightarrow \varepsilon$$

First(abcd) = { a }

First(ABC) = { a, d }

First B não tem
$$\varepsilon$$
 à direita e tem A e C

First(BzSB) = { b, c, a, d, x, y }

First(CzSB) = { x, y, z }

First(SABC) = { a, d }

 $First(C) = \{x, y, \varepsilon\}$

 $First(DAB) = \{a, d\}$

 $First(DCe) = \{x, y, e\}$

 $First(DC) = \{x, y, \varepsilon\}$



Material Prof. Daniel Lucrédio (UFSCar)

Gramática

$$S \to A B$$

$$A \rightarrow a A \mid a \mid d$$

$$B \rightarrow b B \mid c \mid A \mid Cd$$

$$C \rightarrow x \mid y \mid \varepsilon$$

$$D \to \varepsilon$$

$$First(abcd) = \{a\}$$

$$First(ABC) = \{a, d\}$$

$$First(AxCd) = \{a, d\}$$

ϵ C tem ϵ à direita, mas é seguido de z

$$First(CzSB) = \{x, y, z\}$$

$$First(SABC) = \{a, d\}$$

$$First(C) = \{x, y, \varepsilon\}$$

$$First(DAB) = \{a, d\}$$

$$First(DCe) = \{x, y, e\}$$

$$First(DC) = \{x, y, \varepsilon\}$$



Material Prof. Daniel Lucrédio (UFSCar)

Gramática

 $D \to \varepsilon$

$$S \to A B$$

$$A \to a A \mid a \mid d$$

$$B \to b B \mid c \mid A \mid Cd$$

$$C \to x \mid y \mid \varepsilon$$

First(abcd) = { a }

First(ABC) = { a,d }

First(AxCd) = { a,d }

First(BzSB) = { b,c,a,d,x,y }

First A não tem
$$\varepsilon$$
 à direita

First(SABC) = { a,d }

First(C) = { x,y, ε }

First(DAB) = { a,d }

First(DCe) = { x,y, ε }



Material Prof. Daniel Lucrédio (UFSCar)

Gramática

$$S \to A B$$

$$A \to a A \mid a \mid d$$

$$B \to b B \mid c \mid A \mid Cd$$

$$C \to x \mid y \mid \varepsilon$$

$$D \to \varepsilon$$

First(abcd) = { a }

First(ABC) = { a, d }

First(AxCd) = { a, d }

First(BzSB) = { b, c, a, d, x, y }

First(CzSB) = { x, y, z }

First
$$C \text{ tem } \varepsilon \text{ à direita e está sozinho}$$

First(DAB) = { a, d }

First(DCe) = { x, y, \varepsilon} }

First(DC) = { x, y, \varepsilon} }



Material Prof. Daniel Lucrédio (UFSCar)

Gramática

 $D \to \varepsilon$

$$S \to A B$$

$$A \to a A \mid a \mid d$$

$$B \to b B \mid c \mid A \mid Cd$$

$$C \to x \mid y \mid \varepsilon$$

$$First(abcd) = \{ a \}$$

$$First(ABC) = \{ a, d \}$$

$$First(AxCd) = \{ a, d \}$$

$$First(BzSB) = \{ b, c, a, d, x, y \}$$

$$First(CzSB) = \{ x, y, z \}$$

$$First(SABC) = \{ a, d \}$$

E D tem ε à direita, mas é seguido de A

$$First(DAB) = \{ a, d \}$$

$$First(DCe) = \{ x, y, e \}$$

$$First(DC) = \{ x, y, \epsilon \}$$



Material Prof. Daniel Lucrédio (UFSCar)

Gramática

 $D \to \varepsilon$

$$S \to A B$$

$$A \to a A \mid a \mid d$$

$$B \to b B \mid c \mid A \mid Cd$$

$$C \to x \mid y \mid \varepsilon$$

$$First(abcd) = \{ a \}$$

$$First(ABC) = \{ a, d \}$$

$$First(AxCd) = \{ a, d \}$$

$$First(BzSB) = \{ b, c, a, d, x, y \}$$

$$First(CzSB) = \{ x, y, z \}$$

$$First(SABC) = \{ a, d \}$$

D tem ε à direita, mas é seguido de \mathcal{C} , que tem ε , e que é seguido de e

$$First(DCe) = \{ x, y, e \}$$
$$First(DC) = \{ x, y, \epsilon \}$$



Material Prof. Daniel Lucrédio (UFSCar)

Gramática

$$S \to A B$$

$$A \to a A A$$

$$A \rightarrow a A \mid a \mid d$$

$$B \to b B \mid c \mid A \mid Cd$$

$$C \rightarrow x \mid y \mid \varepsilon$$

$$D \to \varepsilon$$

$$First(abcd) = \{a\}$$

$$First(ABC) = \{a, d\}$$

$$First(AxCd) = \{a, d\}$$

$$First(BzSB) = \{b, c, a, d, x, y\}$$

$$First(CzSB) = \{x, y, z\}$$

$$First(SABC) = \{a, d\}$$

$$First(C) = \{x, y, \varepsilon\}$$

D tem ε à direita, mas é seguido de C, que tem ε

$$First(DC) = \{x, y, \varepsilon\}$$



Outro Exemplo Usando Notação de CFGs

Gramática

$$E \to T E'$$

$$E' \to + T E' \mid \varepsilon$$

$$T \to F T'$$

$$T' \to * F T' \mid \varepsilon$$

$$F \to (E) \mid id$$

$$First(E) = \{ (, id \} \}$$

$$First(T) = \{ (, id \} \}$$

$$First(F) = \{ (, id \} \}$$

$$First(E') = \{ +, \epsilon \}$$

$$First(T') = \{ *, \epsilon \}$$



Exemplos de Conjuntos First da Linguagem **CPRL**

```
constDecl = "const" constId ":=" literal ";" .
  First(constDec1) = { "const" }
```

```
varDecl = "var" identifiers ":" typeName ";" .
First(varDecl) = { "var" }
```

arrayTypeDecl = "type" typeId "=" "array" ... ";" . First(arrayTypeDecl) = { "type" }



Exemplos de Conjuntos *First* da Linguagem **CPRL**

```
initialDecl = constDecl | varDecl | arrayTypeDecl .
   First(initialDecl) = { "const", "var", "type" }
```

```
statementPart = "begin" statements "end" .
First(statementPart) = { "begin" }
```

```
loopStmt = ( "while" booleanExpr )? "loop" ... ";" .
  First(loopStmt) = { "while", "loop" }
```



Conjuntos Follow (Seguidores)

- O conjunto de todos os símbolos terminais que seguem imediatamente após a expressão sintática A, em alguma forma sentencial, é denotado por Follow(A);
- \blacksquare Ou seja, é o conjunto de terminais α , tal que existe uma derivação na forma $S \Rightarrow \alpha A \alpha \beta$
 - $Follow(A) = \{ a \mid S \stackrel{\uparrow}{\Rightarrow} \alpha A a \beta \}$
- A expressão sintática A representa obrigatoriamente um símbolo não-terminal;
- Se A é o símbolo mais à direita em alguma forma sentencial, então \$ (símbolo de marcação de fim da entrada, análogo ao EOF), está em Follow(A);
- Entender os conjuntos Follow é importante não somente para o desenvolvimento do parser, mas também para recuperação de erros, pois usaremos Follow(A)durante a recuperação de erros quando houver a tentativa de análise de A. Para computar Follow(A), devemos analisar todas as regras que referenciam A;
- A computação dos conjuntos Follow pode ser mais complicada do que a computação dos conjuntos First 😂 😭 🔞



Regras para Computar os Conjuntos Follow

- \blacksquare Computando Follow(A):
 - Insira \$ em Follow(S), onde S é o símbolo inicial e \$ é o símbolo de marcação de fim de entrada;
 - Se há uma produção na forma $A \Rightarrow \alpha B\beta$, então todos os elementos em $First(\beta)$, com exceção de ε , são inseridos em Follow(B);
 - Se há uma produção na forma $A \Rightarrow \alpha B$, ou uma produção na forma $A \Rightarrow \alpha B\beta$ onde $First(\beta)$ contém ε (ou seja, $\beta \Rightarrow \varepsilon$), então todos os elementos em Follow(A) estarão em Follow(B).



Regras para Computar os Conjuntos Follow

- \blacksquare Computando Follow(T):
 - Considere todas as produções similares às abaixo:
 - N = STU.
 - N = S(T) * U.
 - ightharpoonup N = S(T)? U.
 - ightharpoonup Follow(T) inclui First(U);
 - Se U puder ser vazio, então Follow(T) também inclui Follow(N);
 - Considere todas as produções similares às abaixo:
 - N = ST.
 - N = S(T) *
 - N = S(T)?.
 - \blacksquare Em todos esses casos, Follow(T) inclui Follow(N);
 - Se T ocorre na forma (T) * ou(T) +, então Follow(T) inclui First(T)



Estratégia para Computar os Conjuntos Follow

 Usar uma abordagem de cima para baixo, ou seja, iniciar com a primeira regra, a do símbolo inicial, e trabalhar em direção às regras mais simples.



Um Exemplo, Usando Notação de CFGs

Material Prof. Daniel Lucrédio (UFSCar)

Gramática

$$S \to A B$$

$$A \to a A \mid a \mid d$$

$$B \to b B \mid c \mid A \mid Cd$$

$$C \to x \mid y \mid \varepsilon$$

$$D \to \varepsilon$$

$$Follow(S) = \{\$\}$$

$$Follow(A) = \{b, c, a, d, x, y, \$\}$$

$$Follow(B) = \{\$\}$$

$$Follow(C) = \{d\}$$

$$Follow(D) = \{\}$$

vazio, pois como D é inalcançável, não há seguidores de D



Outro Exemplo Usando Notação de CFGs

Gramática

$$E \to T E'$$

$$E' \to + T E' \mid \varepsilon$$

$$T \to F T'$$

$$T' \to *F T' \mid \varepsilon$$

$$F \to (E) \mid id$$

$$Follow(E) = \{ \}, \} \}$$
 $Follow(E') = \{ \}, \} \}$
 $Follow(T) = \{ +, \}, \} \}$
 $Follow(T') = \{ +, \}, \} \}$
 $Follow(F) = \{ +, *, \}, \} \}$



Exemplos de Conjuntos *Follow* da Linguagem **CPRL**

- O que pode seguir uma initialDecl?
 - A partir da regra:

```
initialDecls = ( initialDecl )* .
```

Sabemos que qualquer initialDecl pode seguir uma initialDecl, então o cónjunto Follow para initialDecl inclui o conjunto First de initialDecl, ou seja, "const", "var" e "type";

Das regras:

```
declarativePart = initialDecls subprogramDecls .
subprogramDecls = ( subprogramDecl )* .
subprogramDecl = procedureDecl | functionDecl .
```

Sabemos que uma procedureDecl ou uma functionDecl pode seguir uma initialDecl, então o conjunto Follow para initialDecl inclui "procedure" e "function".

Exemplos de Conjuntos Follow da Linguagem CPRL

Das regras:

```
program = declarativePart statementPart "." .
statementPart = "begin" statements "end" .
```

Sabemos que statementPart pode seguir uma initialDecl, então o conjunto Føllow de initialDecl inclui "begin";

■ Conclusão:

```
Follow(initialDecl) = { "const", "var", "type", "procedure", "function", "begin" }
```



■ Um fator sintático na forma (E) * é reconhecido pelo seguinte algoritmo:

enquanto o símbolo atual estiver em First(E): aplique o algoritmo que reconhece E fim enquanto

Restrição Gramatical 1: First(E) e Follow((E) *) têm que ser disjuntos nesse contexto, ou seja:

$$First(E) \cap Follow((E) *) = \emptyset$$

Porque?



43/86 Análise Descendente Recursiva Refinamento 5 (exemplo)

Considere a regra para initialDecls:

```
initialDecls = ( initialDecl )* .
```

O método da CPRL para analisar initialDecls é:

```
public void parseInitialDecls() {
    while ( scanner.getSymbol() == Symbol.constRW
            scanner.getSymbol() == Symbol.varRW
            scanner.getSymbol() == Symbol.typeRW ) {
        parseInitialDecl();
```

Na CPRL, os símbolos "const", "var", e "type" não podem seguir initialDecls. Quais podem?

Métodos Auxiliares na Classe Symbol

 A classe Symbol fornece vários métodos auxiliares para testar as propriedades dos símbolos:

```
public boolean isReservedWord()
public boolean isInitialDeclStarter()
public boolean isSubprogramDeclStarter()
public boolean isStmtStarter()
public boolean isLogicalOperator()
public boolean isRelationalOperator()
public boolean isAddingOperator()
public boolean isMultiplyingOperator()
public boolean isLiteral()
public boolean isExprStarter()
```



Método isStmtStarter()

```
/**
 * Retorna true caso o símbolo possa iniciar uma instrução.
 */
public boolean isStmtStarter() {
    return this == Symbol.exitRW
        || this == Symbol.identifier
        || this == Symbol.ifRW
        || this == Symbol.loopRW
        || this == Symbol.whileRW
        || this == Symbol.readRW
        || this == Symbol.writeRW
        || this == Symbol.writelnRW
        | this == Symbol.returnRW;
```



Método isInitialDeclStarter()

```
/**
* Retorna true caso o símbolo possa iniciar uma declaração inicial.
public boolean isInitialDeclStarter() {
    return this == Symbol.constRW
        || this == Symbol.varRW
        || this == Symbol.typeRW;
```



Usando os Métodos Auxiliares da Classe Symbol

Usando os métodos auxiliares da classe Symbol, podemos escrever o método parseInitialDecls() da seguinte forma:

```
public void parseInitialDecls() {
    while ( scanner.getSymbol().isInitialDeclStarter() ) {
        parseInitialDecl();
```



 Dado que um fator sintático na forma (E) + é equivalente a E(E)*, um fator sintático na forma (E) + é reconhecido pelo seguinte algoritmo:

```
aplique o algoritmo que reconhece E
enquanto o símbolo atual estiver em First(E):
  aplique o algoritmo que reconhece E
fim enquanto
```

De forma equivalente, o algoritmo para reconhecer (E) + pode ser escrito usando um laço com teste no final:

```
faça
  aplique o algoritmo que reconhece E
  saia quando o símbolo atual não estiver em First(E)
fim faça
```



Em Java, como sabemos, a estrutura de repetição que realiza o teste no fim da execução do bloco de código é o do-while. Sendo assim, o algoritmo implementado em Java se parecerá com algo assim:

faça aplique o algoritmo que reconhece E enquanto o símbolo atual estiver em First(E)

Restrição Gramatical 2: Se E pode gerar uma string vazia, então First(E) e Follow((E)+) têm que ser disjuntos nesse contexto, ou seja:

$$First(E) \cap Follow((E)+) = \emptyset$$



■ Um fator sintático na forma (E)? é reconhecido pelo seguinte algoritmo:

se o símbolo atual estiver em First(E), então aplique o algoritmo que reconhece Efim se

Restrição Gramatical 3: First(E) e Follow((E)?) têm que ser disjuntos nesse contexto, ou seja:

$$First(E) \cap Follow((E)?) = \emptyset$$

Pela mesma razão anterior.



Método Auxiliar matchCurrentSymbol()

- O método matchCurrentSymbol() é similar ao método match(), com a exceção de que ele não possui parâmetros e não lança uma exceção. Ele simplesmente avança o scanner;
- O método matchCurrentSymbol() é usado quando já sabemos que o próximo símbolo do fluxo de entrada é o que queremos. Poderíamos usar o método match() para esse propósito, mas o método matchCurrentSymbol() é um pouco mais eficiente;
- Código do método matchCurrentSymbol():

```
private void matchCurrentSymbol() throws IOException {
    scanner.advance();
```



52/86 Análise Descendente Recursiva Refinamento 7 (exemplo)

Considere a regra da instrução exit: exitStmt = "exit" ("when" booleanExpr)? ";" .

O método de análise da instrução exit é:

```
verifica a cláusula
public void parseExitStmt() {
                                                   when, que é opcional
    match( Symbol.exitRW );
    if ( scanner.getSymbol() == Symbol.whenRW ) {
        matchCurrentSymbol();
        parseExpression();
                                           um pouco mais
                                            eficiente que
    match( Symbol.semicolon );
                                        match(Symbol.whenRW)
```



Análise Descendente Recursiva Refinamento 7 (exemplo)

- O conjunto First da cláusula opcional when é simplesmente { "when" }, então usamos a palavra reservada when para nos dizer se devemos ou não processar a cláusula when;
- Para pensar:
 - Qual o conjunto Follow para a cláusula opcional when?
 - Qual problema haveria se o mesmo contivesse a palavra reservada "when"?



■ Um fator sintático na forma E | F é reconhecido pelo seguinte algoritmo:

```
se o símbolo atual estiver em First(E), então
   aplique o algoritmo que reconhece E
senão se o símbolo atual estiver em First(F), então
  aplique o algoritmo que reconhece F
senão
  erro de análise
fim se
```

Restrição Gramatical 4: First(E) e First(F) têm que ser disjuntos nesse contexto, ou seja:

$$First(E) \cap First(F) = \emptyset$$



Análise Descendente Recursiva Refinamento 8 (exemplo)

Considere a regra da CPRL para initialDecl: initialDecl = constDecl | varDecl | arrayTypeDecl .

essa lógica também pode ser implementada usando um switch

O método da CPRL de análise para initialDecl é:

```
public void parseInitialDecl() {
    if ( scanner.getSymbol() == Symbol.constRW ) {
        parseConstDecl();
    } else if ( scanner.getSymbol() == Symbol.varRW ) {
        parseVarDecl();
    } else if ( scanner.getSymbol() == Symbol.typeRW ) {
        parseArrayTypeDecl();
    } else {
        ... // lançar uma InternalErrorException
```



Gramáticas LL(1)

- Se uma gramática satisfaz as restrições impostas pelas regras de análise apresentadas anteriormente, então essa gramática é chamada de Gramática LL(1);
- A análise sintática descendente recursiva com um símbolo de loøkahead só pode ser aplicada se a gramática for LL(1);
 - Left to Right with Leftmost Derivation;
 - L: a leitura do arquivo fonte é feito da esquerda para a direita;
 - L: a descida na árvore de análise é feita da esquerda para a direita;
 - 1: um token de lookahead:
- Nem todas as gramáticas são LL(1);
 - Por exemplo, qualquer gramática que tem recursão à esquerda não é LL(1).

Gramáticas LL(1)

- Na prática, a sintaxe da maioria das linguagens de programação podem ser definidas, ou pelo menos ser bem aproximadas, por uma gramática LL(1);
 - Por exemplo, realizar transformações na gramática, como eliminar recursão à esquerda;
- A expressão "descendente recursiva" refere-se ao fato que descemos (top-down) a árvore de análise usando chamadas à funções/métodos recursivos.



Análise Descendente Recursiva

A parte "recursiva" da expressão "descendente recursiva", vem do uso das chamadas recursivas no parser, por exemplo, para analisar instruções de laço aninhadas:

```
parseLoop()
                   // chamado na análise do laço mais externo
  parseStatements()
     parseLoop() // chamado na análise do laço mais interno
```

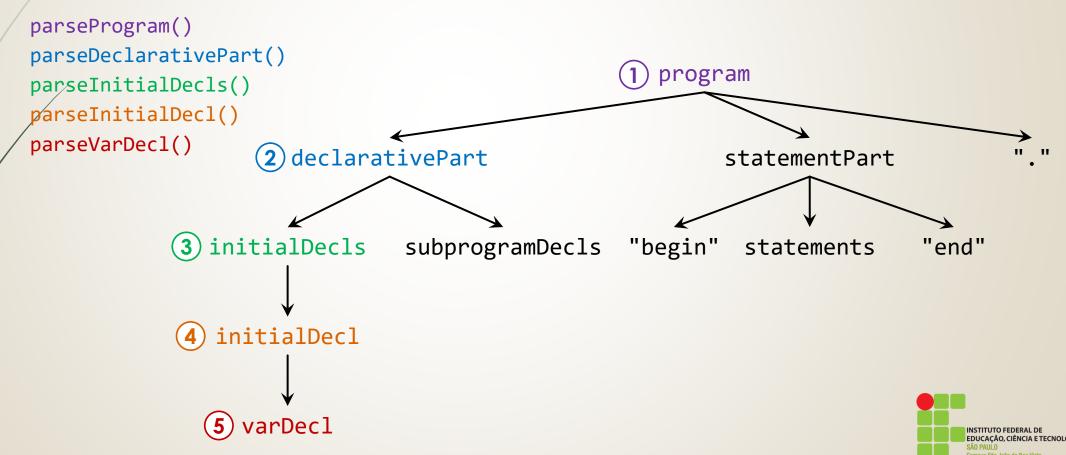
Para a parte "descendente" da expressão "descendente recursiva", considere uma porção da árvore de análise para um programa simples escrito em CPRL:

```
var x : Integer;
begin
end.
```



59/86 Análise Descendente Recursiva

 Na árvore de análise abaixo, os números à esquerda dos nós correspondem à ordem de invocação dos métodos, ou seja, esses são os cinco primeiros métodos de análise durante a análise do programa.



Desenvolvimento do Parser da CPRL

- Haverá três grandes versões do parser para o nosso projeto do compilador:
 - Versão 1 (Projeto 2): reconhecimento da linguagem, baseada em uma gramática livre de contexto, com verificações mínimas em relação às restrições da linguagem;
 - Versão 2 (Projeto 3): inserção da recuperação de erros;
 - Versão 3 (Projeto 4): inserção da geração das árvores sintáticas abstratas.



Desenvolvimento do Parser da CPRL

Versão 1: Reconhecimento da Linguagem (Projeto 2)

- Usar os refinamentos discutidos anteriormente:
- Verificar se as restrições gramaticais, em termos dos conjuntos First e Follow, são satisfeitas pela gramática da CPRL;
- Usar a gramática para desenvolver a versão 1 do parser:
 - Requererá a análise da gramática;
 - Computação dos conjuntos First e Follow.



Variáveis versus Valores Nomeados

 Da perspectiva da gramática, não há distinção real entre uma variável e um valor nomeado:

```
variable = ( varId | paramId ) ( "[" expression "]" )* .
namedValue = variable .
```

- Ambos são analisados de forma similar, mas faremos uma distinção baseada no contexto onde os identificadores aparecem;
- Por exemplo, considere a instrução de atribuição:

```
x := y;
```

O identificador "x" representa a variável e o identificador "y" representa o valor nomeado.



Variáveis versus Valores Nomeados

- Simplificando, um identificador é uma variável se estiver situado do lado esquerdo da uma instrução de atribuição e será considerado um valor nomeado se for usado em uma expressão;
- A distinção entre uma variável e um valor nomeado se tornará importante quando formos lidar com os tópicos relativos à recuperação de erros e geração de código, pois serão tratados de forma diferente.



Lidando com as Limitações da Gramática

- Da forma que está, a gramática da CPRL "não é bem" do tipo LL(1);
- Exemplo: Realizando a análise da regra statement:

```
statement = assignmentStmt | ifStmt | loopStmt | exitStmt
            readStmt | writeStmt | writeInStmt
           procedureCallStmt | returnStmt .
```

- Usamos o símbolo de lookahead para selecionar o método de análise:
 - "if" → analisar uma instrução "if"
 - "while" → analisar uma instrução while
 - "loop" → analisar uma instrução de laço
 - identifier → analisar uma instrução de atribuição ou uma instrução de chamada de função, mas qual delas?
- Um identificador está no conjunto First tanto de uma instrução de atribuição quanto numa instrução de chamada de procedimento.

Lidando com as Limitações da Gramática

Um problema similar existe quando se analisa uma regra factor:

```
factor = "not" factor | constValue | namedValue
       functionCall | "(" expression ")" .
```

Um identificador está no conjunto First de constValue, namedValue, e functionCall.



Possíveis Soluções

- Usar um token de lookahead adicional (LL(2)):
 - Se um símbolo que segue um identificador é um "[" ou ":=", analise uma instrução de atribuição;
 - Se é um "(" ou ";", analise uma instrução de chamada de procedimento;
- Reprojetar ou fatorar a gramática, por exemplo, trocar

$$s = i \times | i y .$$
por
 $s = i (\times | y) .$

Usar uma tabela de identificadores (tabela de símbolos) para armazenar informações sobre como o identificador foi declarado e então, mais tarde, usar essa informação para determinar se o identificador é uma constante, uma variável, o nome de um procedimento etc. Usaremos essa abordagem!



67/86 Classe IdTable Versão 1

- Criaremos uma versão preliminar da classe IdTable para nos ajudar a acompanhar os identificadores que foram declarados e nos auxiliar com as regras básicas de escopo na análise de restrições;
- Tipos dos identificadores (enumeração IdType):

```
public enum IdType {
    constantId,
    variableId,
    arrayTypeId,
    procedureId,
    functionId;
```

A classe IdTable será estendida nas próximas versões do projeto de modo a executar uma análise mais completa das regras de escopo da CPRL.

Exemplo de Procedimento (Escopo)

```
var x : Integer;
var y : Integer;
procedure p is
  var x : Integer;
  var n : Integer;
begin
  x := 5; // qual x?
  n := y; // qual y?
end p;
begin
  x := 8; // qual x?
end.
```



Lidando com Escopos Dentro da Classe IdTable

- Variáveis e constantes podem ser declaradas no nível do programa ou no nível de um subprograma, introduzindo assim o conceito de escopo;
- A classe IdTable precisará buscar por nomes tanto dentro do escopo atual e possivelmente em escopos mais externos;
- A classe IdTable é implementada como uma pilha de mapas, associando a string dos identificadores com seu tipo (IdType);
 - Quando um novo escopo é aberto, um novo mapa é empilhado;
 - A busca por uma declaração envolve pesquisar dentro do nível atual, nas declarações contidas no mapa no topo da pilha, e então dentro de escopos mais externos, ou seja, em mapas abaixo do topo da pilha.



Métodos Importantes da Classe IdTable

```
* Abre um novo escopo para identificadores.
public void openScope()
/**
 * Fecha o escopo mais interno.
public void closeScope()
/**
 * Insere um token e seu tipo no nível de escopo atual.
 * @throws ParserException se o identificador do token já estiver definido
                            dentro do escopo atual.
public void add( Token idToken, IdType idType ) throws ParserException
/**
* Retorna o IdType associado com o texto do token do identificador. Retorna null
  se o identificador não for encontrado. Esse método busca em escopos mais externos
  caso necessário.
public IdType get( Token idToken )
```

Adicionando Declarações na IdTable

- Quando um identificador é declarado, o parser tentará adicionar o token do identificador e seu tipo à tabela de identificadores dentro do escopo atual;
 - Lança uma exceção caso um identificador com o mesmo nome, ou seja, o mesmo texto do token, já tiver sido previamente declarado no escopo atual;
- Por exemplo, no método parseConstDecl()

```
idTable.add( constId, IdType.constantId );
```

Lança uma ParserException se o identificador já estiver definido no escopo atual



Usando uma IdTable para Verificar Ocorrências Aplicadas dos Identificadores

- Quando um identificador é encontrado em uma instrução de um programa ou subprograma, o parser vai:
 - Verificar se o identificador foi declarado;
 - Usar a informação sobre como o identificador foi declarado para facilitar sua análise correta, por exemplo, você não pode atribuir um valor à um identificador que foi declarado como uma constante.



Usando uma IdTable para Verificar Ocorrências Aplicadas dos Identificadores

```
// no método parseFactor()
} else if ( scanner.getSymbol() == Symbol.identifier ) {
    // lida com os identificadores baseando-se se eles foram
    // declarados como variáveis, constantes ou funções.
    Token idToken = scanner.getToken();
    IdType idType = idTable.get( idToken );
    if ( idType != null ) {
        if ( idType == IdType.constantId ) {
            parseConstValue();
        } else if ( idType == IdType.variableId ) {
            parseNamedValue();
        } else if ( idType == IdType.functionId ) {
            parseFunctionCall();
        } else {
            throw error( "Identifier \"" + scanner.getToken() +
                         "\" is not valid as an expression." );
    } else {
        throw error( "Identifier \"" + scanner.getToken() +
                       "\" has not been declared." );
```

Exemplo



Analisando uma Declaração de Procedimento

```
// procedureDecl = "procedure" procId ( formalParameters )?
                   "is" initialDecls statementPart procId ";" .
match( Symbol.procedureRW );
Token procId = scanner.getToken();
match( Symbol.identifier );
idTable.add( procId, IdType.procedureId );
idTable.openScope();
if ( scanner.getSymbol() == Symbol.leftParen ) {
    parseFormalParameters();
match( Symbol.isRW );
parseInitialDecls();
parseStatementPart();
idTable.closeScope();
Token procId2 = scanner.getToken();
match( Symbol.identifier );
if ( !procId.getText().equals( procId2.getText() ) ) {
    throw error(procId2.getPosition(),
                "Procedure name mismatch.");
match( Symbol.semicolon );
```

Exemplo

Note que o nome do procedimento é definido no escopo mais externo (do programa), mas seus parâmetros e declarações iniciais são definidos dentro do escopo do procedimento.



Analisando uma Declaração de Procedimento

```
// procedureDecl = "procedure" procId ( formalParameters )?
                   "is" initialDecls statementPart procId ";" .
match( Symbol.procedureRW );
Token procId = scanner.getToken();
match( Symbol.identifier );
idTable.add( procId, IdType.procedureId );
idTable.openScope();
if ( scanner.getSymbol() == Symbol.leftParen ) {
    parseFormalParameters();
match( Symbol.isRW );
parseInitialDecls();
parseStatementPart();
idTable.closeScope();
Token procId2 = scanner.getToken();
match( Symbol.identifier );
if ( !procId.getText().equals( procId2.getText() ) ) {
    throw error(procId2.getPosition(),
                "Procedure name mismatch.");
match( Symbol.semicolon );
```

Exemplo

Note também a verificação se os nomes dos procedimentos (procId e procId2) combinam. Tecnicamente, a garantia que os nomes dos procedimentos combinam vai além da análise sintática e representa mais uma verificação de restrição. Do ponto de vista da gramática livre de contexto, eles são apenas identificadores.



Analisando uma Instrução Exemplo

```
Symbol symbol = scanner.getSymbol();
if ( symbol == Symbol.identifier ) {
    IdType idType = idTable.get( scanner.getToken() );
    if ( idType != null ) {
        if ( idType == IdType.variableId ) {
            parseAssignmentStmt();
        } else if ( idType == IdType.procedureId ) {
            parseProcedureCallStmt();
        } else {
            throw error(...);
    } else {
        throw error(...);
} else if ( symbol == Symbol.ifRW ) {
    parseIfStmt();
} else if ( symbol == Symbol.loopRW || symbol == Symbol.whileRW ) {
    parseLoopStmt();
} else if ( symbol == Symbol.exitRW ) {
    parseExitStmt();
. . .
```

77/86 Classe ErrorHandler

- Usada para que haja consistência no relatório de erros;
- Implementa o padrão de projeto Singleton;
- Para obter uma instância de ErrorHandler deve-se invocar:

```
ErrorHandler.getInstance();
```



78/86 Métodos Chave da Classe ErrorHandler

```
/**
* Reporta um erro. Para o processo de compilação se
 * uma quantidade máxima de erros for gerada.
 */
public void reportError( CompilerException e )
/**
* Reporta o erro e termina a compilação.
public void reportFatalError( Exception e )
/**
* Reporta um aviso e continua a compilação.
 */
public void reportWarning( String warningMessage )
```



Usando a ErrorHandler para a Versão 1 do Parser (Projeto 2)

- → A Versão 1 (Projeto 2) do parser não implementará a recuperação de erros. Quando um erro é encontrado, o parser imprimirá a mensagem de erro e terminará a execução;
- De modo a suavizar a transição para a recuperação de erros para a próxima versão do parser, a maioria dos métodos de análise empacotarão a lógica básica em um bloco try/catch;
- Qualquer método de análise que invoque os métodos match() ou add() de IdTable precisarão ter um bloco try/catch;
- O relatório de erros será implementado dentro da cláusula catch do bloco try/catch.



80/86 Usando a ErrorHandler para a Versão 1 do Parser (Projeto 2)

```
public void parseAssignmentStmt() throws IOException {
    try {
                                          As instruções de
        parseVariable();
                                           análise ficarão
        match( Symbol.assign );
                                        empacotadas dentro
        parseExpression();
                                            de um bloco
        match( Symbol.semicolon );
                                             try/catch
    } catch ( ParserException e ) {
        ErrorHandler.getInstance().reportError( e );
        exit();
```

Essa abordagem nos fornecerá um alicerce que nós usaremos para a implementação da recuperação de erros

81/86 Implementando os Métodos parseVariable() e parseNamedValue()

- Para implementar os métodos parseVariable() e parseNamedValue() usaremos um método auxiliar que proverá uma lógica comum aos dois métodos;
- Esse método auxiliar não lidará com quaisquer exceções geradas pelo parser (ParseException), lançando-as ao método chamador para que possam ser manipuladas apropriadamente;
- Ume esboço desse método auxiliar, chamado de parseVariableExpr(), será mostrado a seguir;
- Ambos os métodos parseVariable() e parseNamedValue() invocam parseVariableExpr() com o intuito de auxiliar na análise da regra gramatical que trata de variáveis.



Método parseVariableExpr()

```
// analisa a regra gramatical abaixo:
// variable = ( varId | paramId ) ( "[" expression "]" )* .
public void parseVariableExpr() throws IOException, ParserException {
    Token idToken = scanner.getToken();
    match( Symbol.identifier );
    IdType idType = idTable.get( idToken );
    if ( idType == null ) {
        String errorMsg = "Identifier \"" + idToken +
                          "\" has not been declared.";
        throw error( idToken.getPosition(), errorMsg );
    } else if ( idType != IdType.variableId ) {
        String errorMsg = "Identifier \"" + idToken +
                          "\" is not a variable.";
        throw error( idToken.getPosition(), errorMsg );
    while ( scanner.getSymbol() == Symbol.leftBracket ) {
        matchCurrentSymbol();
        parseExpression();
        match( Symbol.rightBracket );
```

Método parseVariable()

O método parseVariable() simplesmente invoca o método auxiliar para analisar sua regra gramatical.

```
public void parseVariable() throws IOException {
    try {
        parseVariableExpr();
    } catch ( ParserException e ) {
        ErrorHandler.getInstance().reportError(e);
        exit();
```

O método parseNamedValue() é implementado de forma similar.



Breve Discussão Sobre Outros Métodos/Técnicas para Análise Sintática

- Analisadores Descendentes:
 - Análise Sintática Preditiva:
 - Tabela preditiva;
 - Sem recursão;
 - Uso de pilhas;
 - ightharpoonup LL(1): facilidade de implementação, resolução de não-determinismos (ambiguidade, fatoração à esquerda);
 - ightharpoonup LL(k): mesma construção de LL(1), mas com k símbolos de lookahead;
 - LL(*): lookahead variável, sem fatoração à esquerda (gramáticas mais intuitivas);
 - ALL(*) (Adaptative LL(*)): qualquer gramática não-recursiva à esquerda;

$$LL(1) \rightarrow LL(k) \rightarrow LL(*) \rightarrow ALL(*)$$



Breve Discussão Sobre Outros Métodos/Técnicas para Análise Sintática

- Analisadores Ascendentes:
 - Processo de inferência;
 - Construção da árvore de análise sintática de baixo para cima;
 - LR(k): Left to Right with Rightmost Derivation, leitura da esquerda para a direita, produzindo derivações mais à direita ao reverso (inferência recursiva);
 - Difícil de implementar (usar geradores).



86/86 Bibliografia

MOORE JR., J. I. Introduction to Compiler Design: an Object Oriented Approach Using Java. 2. ed. [s.l.]:SoftMoore Consulting, 2020. 284 p.

AHO, A. V.; LAM, M. S.; SETHI, R. ULLMAN, J. D. Compiladores: Princípios, Técnicas e Ferramentas. 2. ed. São Paulo: Pearson, 2008. 634 p.

COOPER, K. D.; TORCZON, L. Construindo Compiladores. 2. ed. Rio de Janeiro: Campus Elsevier, 2014. 656 p.

JOSÉ NETO, J. Introdução à Compilação. São Paulo: Elsevier, 2016. 307 p.

SANTOS, P. R.; LANGOLOIS, T. Compiladores: da teoria à prática. Rio de Janeiro: LTC, 2018. 341 p.