

A amostragem hierárquica é uma técnica utilizada na Renderização e Processamento de imagens, em que o processo de amostragem é dividido em diferentes níveis, onde cada nível foca em capturar detalhes em áreas específicas da cena, usando uma hierarquia de resoluções. Isso permite que detalhes mais finos sejam amostrados onde necessário, enquanto áreas menos detalhadas são renderizadas com menos amostras, melhorando a qualidade da imagem e reduzindo o ruído sem aumentar excessivamente o custo computacional.

Um exemplo prático seria no ray tracing, onde a amostragem hierárquica ajuda a reduzir o número de raios necessários para gerar uma imagem de alta qualidade, dividindo a cena em uma estrutura hierárquica, como uma árvore de subdivisão. Áreas com maior complexidade visual, como bordas ou regiões com sombras, recebem mais amostras para capturar esses detalhes com precisão.

Em resumo, a amostragem hierárquica permite otimizar o uso de recursos computacionais, direcionando-os para partes da cena onde são mais necessários para melhorar a qualidade visual.

O NeRF pega múltiplos pontos ao longo dos raios da câmera para renderizar uma imagem, porém muitos desses pontos acabam em espaços vazios ou em áreas obstruídas, contribuindo pouco para a imagem final.

A amostragem hierárquica no NeRF atua em dois estágios para otimizar a eficiência e a precisão da amostragem de raios:

1. **Primeira Passagem – Amostragem Coarse (Grossa):** Inicialmente, um conjunto de pontos é amostrado ao longo de um raio que atravessa a cena. Esse estágio utiliza amostragem espaçada uniformemente para obter uma visão geral da distribuição de luz e densidade. A rede neural processa esses pontos para estimar onde estão as regiões mais densas ou que merecem mais detalhamento.
2. **Segunda Passagem – Amostragem Fine (Fina):** Usando a informação da primeira passagem, uma amostragem mais densa e focada é feita em regiões com maior densidade de informação, como superfícies visíveis e áreas com alto contraste. Esse segundo estágio permite que o NeRF capture detalhes finos, evitando gastar recursos computacionais em regiões da cena que contribuem pouco para a imagem final.

Essa técnica garante velocidade sem reduzir a qualidade da imagem, pois aloca mais pontos em áreas importantes e evita gastos de recursos computacionais enquanto a rede neural aprende.

<https://viso.ai/deep-learning/neural-radiance-fields/#:~:text=Hierarchical%20Volume%20Sampling,-While%20positional%20encoding&text=NeRFs%20sample%20multiple%20points%20along,for%20faster%2C%20more%20effective%20rendering>.